

Анализ медицинских данных COVID-19 с использованием Apache Spark

Автор: Груданов Николай Алексеевич

Дата: Декабрь 2025

Основная цель

Практическое применение технологий Big Data для эпидемиологического анализа медицинских данных COVID-19 с использованием Apache Spark, SQL и визуализации.

Основные задачи

1. Загрузка данных — Импорт COVID-19 chest X-ray metadata в Apache Spark
2. Предобработка — Очистка, заполнение пропусков, стандартизация диагнозов, категоризация возраста
3. Оценка качества — Анализ полноты данных, дубликатов, пропусков и аномалий
4. SQL-аналитика — Выполнение 5 обязательных аналитических запросов
5. Визуализация — Создание 5 типов графиков с детальным анализом

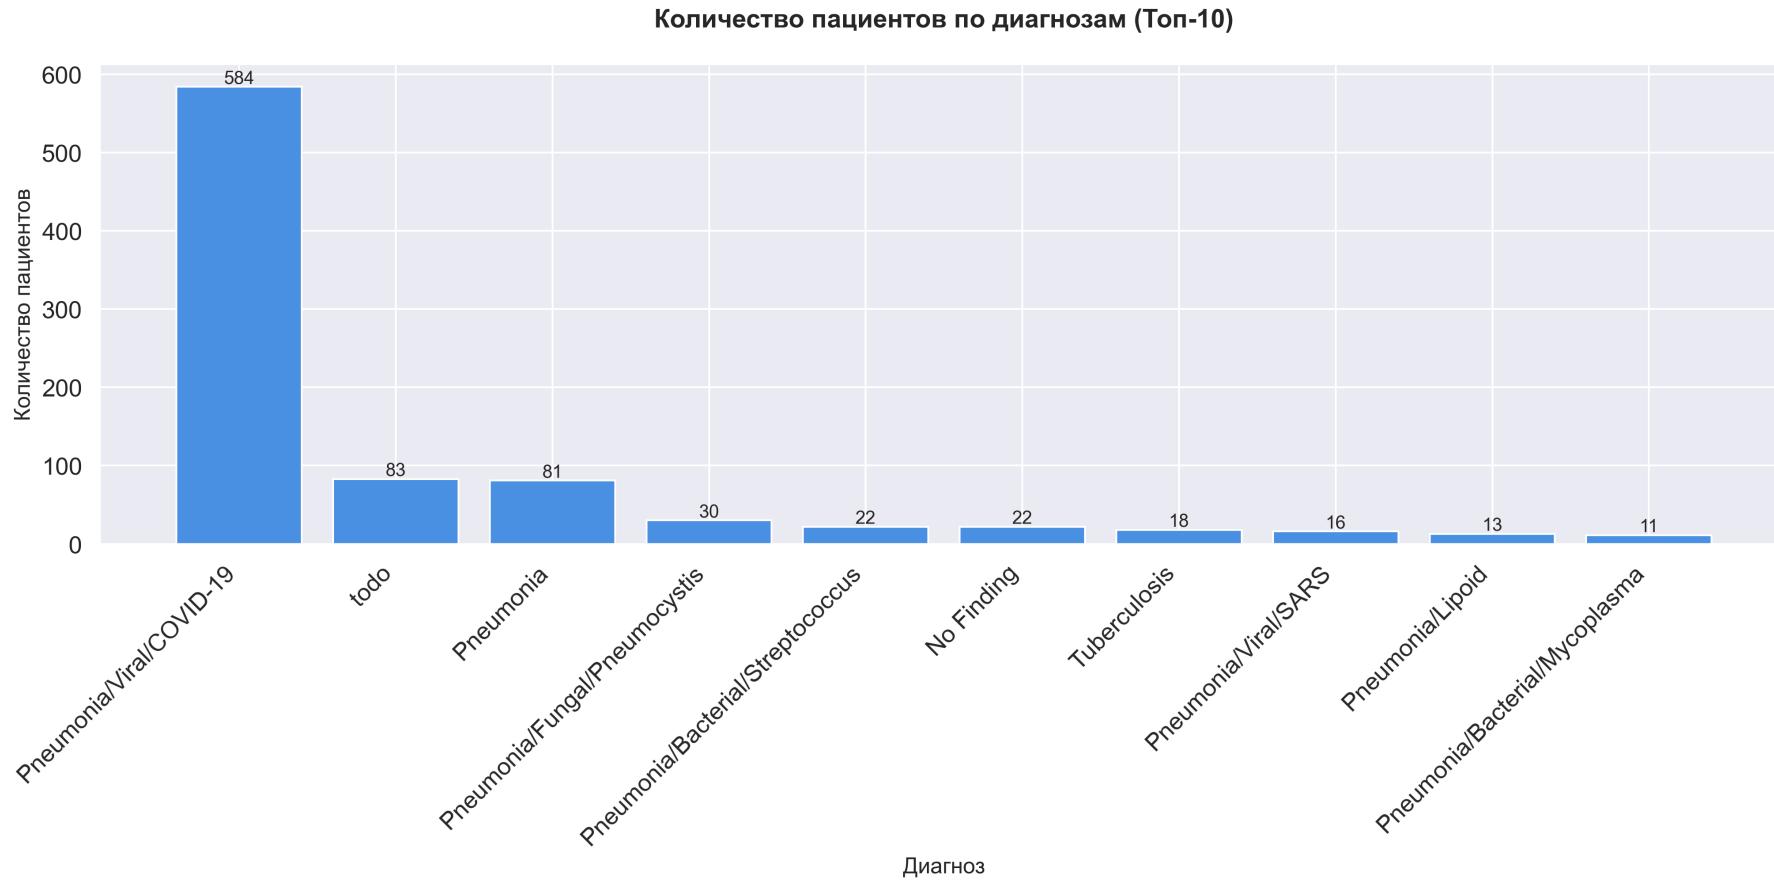
SQL-аналитика (950 пациентов)

Показатель	Значение
Количество пациентов	950 записей
Обработанных после фильтрации	870 записей (91.6%)
Уникальных диагнозов	25 категорий


Ключевые находки

- Доминирующие диагнозы: COVID-19/Viral (59.2%), Пневмония (8.2%), No Finding (8.4%)
- Гендерные различия: Мужчины чаще диагностируются с COVID-19
- Временные паттерны: Убывание случаев с 2020Q4 по 2021Q2
- Возрастная структура: 6.95% пациентов в возрастной группе 30-59 лет

Распределение диагнозов



Временной тренд диагностики COVID-19



Благодарим за внимание!